

0) Název, autor

V DAT1 - Vizualizace dat

Úloha 1 - Poměrová data ve formě jupyter notebooku

Autor: Bc. David Malík

1) Výzkumné otázky (2 - 3)

Výzkumné otázky

1. Jak se liší počet prodaných kusů mezi kategoriemi?
2. Které kategorie mají nejvyšší a nejnižší medián cen?
3. Jak ovlivňuje šíře nabídky produktů úspěšnost prodejů v dané kategorii?

2) Popis výzkumného souboru + validita dat (duplicity, missing values, ověření min,max, ...)


Brazilian E-Commerce Public Dataset by Olist je rozsáhlý a veřejně dostupný dataset, který obsahuje skutečné transakce z brazilského online tržiště Olist v období od roku 2016 do roku 2018. Dataset poskytuje detailní přehled o nákupním chování zákazníků, struktuře prodejů, platebních metodách, hodnocení produktů a logistice.

Dataset se skládá z kolekce propojených datasetů:

- olist_customers_dataset.csv
- olist_geolocation_dataset.csv
- olist_order_items_dataset.csv
- olist_order_payments_dataset.csv
- olist_order_reviews_dataset.csv
- olist_orders_dataset.csv
- olist_products_dataset.csv
- olist_sellers_dataset.csv
- product_category_name_translation.csv

Schéma datasetu

```
In [57]: from IPython.display import Image
dataset_schema_img = Image(filename='images/data_schema.png', width=1024)
display(dataset_schema_img)
```



Import datasetů

```
In [58]: # Import potřebných balíčků
import pandas as pd

# Načtení využívaného datasetu / kolekce datasetů
products_df = pd.read_csv('Brazilian-E-Commerce/olist_products_dataset.csv')
category_translation_df = pd.read_csv('Brazilian-E-Commerce/product_category_name_translation.csv')
order_items_df = pd.read_csv('Brazilian-E-Commerce/olist_order_items_dataset.csv')
```

Dataseť s proměnnými

```
In [59]: from tabulate import tabulate
from itertools import zip_longest

# Nastavení šířky zobrazení výpisu
pd.set_option('display.width', 140)
pd.set_option('display.max_columns', None)

table_data = list(zip_longest(
    products_df.columns,
    category_translation_df.columns,
    order_items_df.columns,
    fillvalue=""
))

# Tabulka datasetů a jejich proměnnými
headers = ["Products", "Category Translation", "Order Items"]
print(tabulate(table_data, headers=headers, tablefmt="simple_outline"))
```

Products	Category Translation	Order Items
product_id	product_category_name	order_id
product_category_name	product_category_name_english	order_item_id
product_name_lenght		product_id
product_description_lenght		seller_id
product_photos_qty		shipping_limit_date
product_weight_g		price
product_length_cm		freight_value
product_height_cm		
product_width_cm		

Validita dat

Pro Products

Výpis prvních 10 řádků datasetu

```
In [60]: print(products_df.drop(columns=['product_id']).head(10))
```

	product_category_name	product_name_lenght	product_description_lenght	product_photos_qty	product_weight_g	product_length_cm	\
0	perfumaria	40.0	287.0	1.0	225.0	16.0	
1	artes	44.0	276.0	1.0	1000.0	30.0	
2	esporte_lazer	46.0	250.0	1.0	154.0	18.0	
3	bebes	27.0	261.0	1.0	371.0	26.0	
4	utilidades_domesticas	37.0	402.0	4.0	625.0	20.0	
5	instrumentos_musicais	60.0	745.0	1.0	200.0	38.0	
6	cool_stuff	56.0	1272.0	4.0	18350.0	70.0	
7	moveis_decoracao	56.0	184.0	2.0	900.0	40.0	
8	eletrodomesticos	57.0	163.0	1.0	400.0	27.0	
9	brinquedos	36.0	1156.0	1.0	600.0	17.0	

	product_height_cm	product_width_cm
0	10.0	14.0
1	18.0	20.0
2	9.0	15.0
3	4.0	26.0
4	17.0	13.0
5	5.0	11.0
6	24.0	44.0
7	8.0	40.0
8	13.0	17.0
9	10.0	12.0

Duplicity

```
In [61]: print("\nPocet duplicitních řádků:", products_df.duplicated().sum())
```

Pocet duplicitních řádků: 0

Chybějící hodnoty

```
In [62]: print("\nPocet chybějících hodnot:")  
print(products_df.isnull().sum())
```

Pocet chybějících hodnot:

product_id	0
product_category_name	610
product_name_lenght	610
product_description_lenght	610
product_photos_qty	610
product_weight_g	2
product_length_cm	2
product_height_cm	2
product_width_cm	2

dtype: int64

Unikátní kategorie

```
In [63]: for column in products_df.select_dtypes(include=['object']).columns:  
print(f"{column}: {products_df[column].nunique()} unikátních hodnot")
```

product_id: 32951 unikátních hodnot

product_category_name: 73 unikátních hodnot

Statistika škálových proměnných

```
In [64]: print(products_df.describe())
```

	product_name_lenght	product_description_lenght	product_photos_qty	product_weight_g	product_length_cm	product_height_cm	\
count	32341.000000	32341.000000	32341.000000	32949.000000	32949.000000	32949.000000	
mean	48.476949	771.495285	2.188986	2276.472488	30.815078	16.937661	
std	10.245741	635.115225	1.736766	4282.038731	16.914458	13.637554	
min	5.000000	4.000000	1.000000	0.000000	7.000000	2.000000	
25%	42.000000	339.000000	1.000000	300.000000	18.000000	8.000000	
50%	51.000000	595.000000	1.000000	700.000000	25.000000	13.000000	
75%	57.000000	972.000000	3.000000	1900.000000	38.000000	21.000000	
max	76.000000	3992.000000	20.000000	40425.000000	105.000000	105.000000	

	product_width_cm
count	32949.000000
mean	23.196728
std	12.079047
min	6.000000
25%	15.000000
50%	20.000000
75%	30.000000
max	118.000000

Výpis kategorií s váhou 0g

```
In [65]: print(f"Počet záznamů s váhou 0g:", products_df[products_df['product_weight_g'] == 0].value_counts().sum())
print(products_df[products_df['product_weight_g'] == 0]['product_category_name'])
```

Počet záznamů s váhou 0g: 4

9769 cama_mesa_banho

13683 cama_mesa_banho

14997 cama_mesa_banho

32079 cama_mesa_banho

Name: product_category_name, dtype: object

Pro Category translation

Výpis prvních 10 řádků datasetu

```
In [66]: print(category_translation_df.head(10))
```

	product_category_name	product_category_name_english
0	beleza_saude	health_beauty
1	informatica_acessorios	computers_accessories
2	automotivo	auto
3	cama_mesa_banho	bed_bath_table
4	moveis_decoracao	furniture_decor
5	esporte_lazer	sports_leisure
6	perfumaria	perfumery
7	utilidades_domesticas	housewares
8	telefonica	telephony
9	relogios_presentes	watches_gifts

Duplicity

```
In [67]: print("\nPočet duplicitních řádků:", category_translation_df.duplicated().sum())
```

Počet duplicitních řádků: 0

Chybějící hodnoty

```
In [68]: print("\nPočet chybějících hodnot:")
print(category_translation_df.isnull().sum())
```

Počet chybějících hodnot:

```
product_category_name      0
product_category_name_english  0
dtype: int64
```

Unikátní kategorie

```
In [69]: for column in category_translation_df.select_dtypes(include=['object']).columns:
print(f"{column}: {category_translation_df[column].nunique()} unikátních hodnot")
```

```
product_category_name: 71 unikátních hodnot
product_category_name_english: 71 unikátních hodnot
```

Pro Order items

Výpis prvních 10 záznamů

```
In [70]: print(order_items_df.drop(columns=['order_id', 'product_id', 'order_item_id', 'seller_id']).head(10))
```

	shipping_limit_date	price	freight_value
0	2017-09-19 09:45:35	58.90	13.29
1	2017-05-03 11:05:13	239.90	19.93
2	2018-01-18 14:48:30	199.00	17.87
3	2018-08-15 10:10:18	12.99	12.79
4	2017-02-13 13:57:51	199.90	18.14
5	2017-05-23 03:55:27	21.90	12.69
6	2017-12-14 12:10:31	19.90	11.85
7	2018-07-10 12:30:45	810.00	70.75
8	2018-03-26 18:31:29	145.95	11.65
9	2018-07-06 14:10:56	53.99	11.40

Duplicity

```
In [71]: print("\nPocet duplicitnich řádků:", order_items_df.duplicated().sum())
```

Pocet duplicitnich řádků: 0

Chybějící hodnoty

```
In [72]: print("\nPocet chybějících hodnot:")
print(order_items_df.isnull().sum())
```

Pocet chybějících hodnot:

order_id	0
order_item_id	0
product_id	0
seller_id	0
shipping_limit_date	0
price	0
freight_value	0

dtype: int64

Unikátní kategorie

```
In [73]: for column in order_items_df.select_dtypes(include=['object']).columns:  
         print(f"{column}: {order_items_df[column].nunique()} unikátních hodnot")
```

```
order_id: 98666 unikátních hodnot  
product_id: 32951 unikátních hodnot  
seller_id: 3095 unikátních hodnot  
shipping_limit_date: 93318 unikátních hodnot
```

Statistika škálových proměnných

```
In [74]: print(order_items_df.describe())
```

	order_item_id	price	freight_value
count	112650.000000	112650.000000	112650.000000
mean	1.197834	120.653739	19.990320
std	0.705124	183.633928	15.806405
min	1.000000	0.850000	0.000000
25%	1.000000	39.900000	13.080000
50%	1.000000	74.990000	16.260000
75%	1.000000	134.900000	21.150000
max	21.000000	6735.000000	409.680000

3) Grafy (případně tabulka) vzhledem k výzkumným otázkám (základní graf + vylepšení)

```
In [75]: # Import potřebných balíčků
import matplotlib.pyplot as plt
import seaborn as sns
```

Paleta barev grafů

```
In [76]: # Definice palety barev
palette = {"rich_black": "#021A1A",
           "dark_green": "#042222",
           "bangladesh_green": "#03624C",
           "mountain_meadow": "#2CC295",
           "caribbean_green": "#00DF82",
           "anti-flash_white": "#F1F7F7"
          }
```

1. Výzkumná otázka:

Jak se liší počet prodaných kusů mezi kategoriemi?

Získání top 10 nejprodávanějších kategorií

```
In [77]: sales_per_product = order_items_df.groupby('product_id')['order_item_id'].sum().reset_index()
sales_per_product = sales_per_product.rename(columns={'order_item_id': 'total_quantity_sold'})

# Seřazení od nejprodávanějšího produktu
sales_per_product = sales_per_product.sort_values('total_quantity_sold', ascending=False)

print(sales_per_product.head())
```

	product_id	total_quantity_sold
8613	422879e10f46682990de24d770e7f83d	793
22112	aca2eb7d00ea1a7b8ebd4e68314663af	640
7079	368c6c730842d78016ad823897a372db	551
10840	53759a2ecddad2bb87a079a1f1519f73	545
19742	99a4788cb24856965c36a24e339b6058	542

```
In [78]: # Přidání anglického překladu
products_with_translation = pd.merge(
    products_df,
    category_translation_df,
    on='product_category_name',
    how='left',
)

# Odstranění produktů bez kategorie
products_with_categories = products_with_translation.dropna(subset=['product_category_name'])

product_sales_with_category = pd.merge(
    sales_per_product,
    products_with_categories[['product_id', 'product_category_name_english']],
    on='product_id',
    how='inner',
)

complete_data = pd.merge(
    product_sales_with_category,
    order_items_df[['product_id', 'price']],
```

```

    on='product_id',
    how='left'
)

sales_per_category = complete_data.groupby('product_category_name_english').agg(
    total_quantity_sold=('total_quantity_sold', 'sum'),
).reset_index()

# Získání top 10 kategorií podle prodeje
top_10_categories = sales_per_category.nlargest(10, 'total_quantity_sold')['product_category_name_english'].tolist()

print(top_10_categories)

# Příprava dat pro histogram a boxplot
filtered_df = complete_data[complete_data['product_category_name_english'].isin(top_10_categories)]

print(sales_per_category.sort_values('total_quantity_sold', ascending=False).head(10))

```

```

['garden_tools', 'furniture_decor', 'bed_bath_table', 'health_beauty', 'computers_accessories', 'watches_gifts', 'sports_leisure', 'housewares', 'cool_stuff', 'perfumery']

```

	product_category_name_english	total_quantity_sold
42	garden_tools	1158251
39	furniture_decor	547198
7	bed_bath_table	527533
43	health_beauty	521963
15	computers_accessories	500063
70	watches_gifts	430823
65	sports_leisure	142672
49	housewares	139666
20	cool_stuff	130299
59	perfumery	105156


Základní graf

```
In [79]: plt.figure(figsize=(10, 7))
sns.barplot = sns.barplot(
    data=filtered_df,
    x='product_category_name_english',
    y='total_quantity_sold',
    order=top_10_categories,
    estimator=sum,
    errorbar=None
)

plt.xticks(rotation=45)

plt.tight_layout()

# Zobrazení grafu
plt.show()
```

Vylepšený graf

```
In [80]: from matplotlib.ticker import FuncFormatter

plt.figure(figsize=(10, 7), facecolor=palette['rich_black'])
ax = sns.barplot(
    data=filtered_df,
    y='product_category_name_english',
    x='total_quantity_sold',
    orient='h',
    order=top_10_categories,
    estimator=sum,
    errorbar=None,
    color=palette['bangladesh_green'],
    edgecolor=palette['dark_green'],
    width=0.6,
    linewidth=0,
)

# Změna barvy prvního baru
ax.patches[0].set_facecolor(palette['mountain_meadow'])

# Nastavení průhledného pozadí os
ax.set_facecolor(palette['rich_black'])

# Popisky os
plt.xlabel("")
plt.ylabel("")
plt.xticks([])
plt.yticks(fontsize=14, fontweight=500, color=palette['anti-flash_white'])

ax.tick_params(
    axis='both',
    which='both',
    left=False,
    bottom=False,
)

# Odstranění rámečků a mřížky
sns.despine(top=True, right=True, bottom=True, left=True)
plt.grid(False)

def format_ticks(value, _):
    if value >= 1_000_000:
```

```

        return f"{value/1_000_000:.1f}M" # 1.5M
    elif value >= 1_000:
        return f"{value/1_000:.0f}K" # 500K
    else:
        return f"{value:.0f}"

ax.xaxis.set_major_formatter(FuncFormatter(format_ticks))

for container in ax.containers:
    ax.bar_label(
        container,
        labels=[format_ticks(val, None) for val in container.datavalues],
        padding=5,
        color=palette['anti-flash_white'],
        fontsize=12,
        fontweight=500
    )

plt.tight_layout()

# Nadpis
plt.suptitle(
    '10 nejprodávanějších kategorií'.upper(),
    y=1.03,
    fontsize=17,
    fontweight=500,
    color=palette['anti-flash_white']
)

# Zobrazení grafu
plt.show()

```

10 NEJPRODÁVANĚJŠÍCH KATEGORIÍ




2. Výzkumná otázka:

Které kategorie mají nejvyšší a nejnižší medián cen?

Základní graf

```
In [81]: # Základní Boxplot
plt.figure(figsize=(10, 7))
sns.boxplot(data=filtered_df, x='product_category_name_english', y='price', order=top_10_categories)
plt.xticks(rotation=45)
plt.title('Distribuce cen v top 10 kategoriích')
plt.show()
```

Distribuce cen v top 10 kategoriích



Vylepšený graf

```
In [82]: plt.figure(figsize=(10, 7), facecolor=palette['rich_black'])

# Mediány cen pro top 10 nejprodávanějších kategorií
median_prices = filtered_df.groupby('product_category_name_english')['price'].median()

# Seřazení top 10 nejprodávanějších kategorií podle mediánu (od nejvyššího)
top_10_ordered = median_prices.sort_values(ascending=False).index.tolist()

# Nastevní boxplotu
ax = sns.boxplot(
    y='product_category_name_english',
    x='price',
    data=filtered_df,
    order=top_10_ordered,
    orient='h',
    width=0.5,
    linewidth=2,
    boxprops=dict(
        edgecolor=palette['rich_black'],
        facecolor=palette['mountain_meadow'],
        linewidth=0,
    ),
    whiskerprops=dict(
        color=palette['bangladesh_green'],
        alpha=1,
        linewidth=5,
    ),
    medianprops=dict(
        color=palette['anti-flash_white'],
        linewidth=4,
    ),
    capprops=dict(
        color=palette['rich_black'],
        linewidth=0
    ),
    flierprops=dict(
        marker='s',
        markersize=4,
        alpha=0.025,
        markerfacecolor=palette['bangladesh_green'],
        markeredgecolor=palette['bangladesh_green'],
        markeredgewidth=0
    )
)
```

```

    )
)

# Nastavení průhledného pozadí os
ax.set_facecolor(palette['rich_black'])

# Popisky os
plt.xlabel("")
plt.ylabel("")
plt.xticks(fontsize=14, fontweight=500, color=palette['anti-flash_white'])
plt.yticks(fontsize=14, fontweight=500, color=palette['anti-flash_white'],
           ticks=range(len(top_10_ordered)), labels=top_10_ordered)
plt.xlim(0, 500)
ax.tick_params(
    axis='both',
    which='both',
    color=palette['anti-flash_white'],
    length=5,
    width=1,
    left=False,
)

# Odstranění rámečků a mřížky
sns.despine(top=True, right=True, bottom=True, left=True)
plt.grid(False)


plt.tight_layout()

# Nadpis
plt.suptitle(
    'Cenové rozdělení 10 neprodávanějších kategorií produktů (v R$)'.upper(),
    y=1.06, # Posunutí výše nad graf
    fontsize=17,
    fontweight=500,
    color=palette['anti-flash_white']
)

plt.show()

```


CENOVÉ ROZDĚLENÍ 10 NEPRODÁVANĚJŠÍCH KATEGORIÍ PRODUKTŮ (V R\$)



3. Výzkumná otázka

Jak ovlivňuje šíře nabídky produktů úspěšnost prodeje v dané kategorii?

```
In [83]: products_per_category = products_with_categories.groupby('product_category_name_english')['product_id'].nunique().reset_index()
products_per_category = products_per_category.rename(columns={'product_id': 'product_count'})

sales_with_counts = pd.merge(
    sales_per_category,
    products_per_category,
    on='product_category_name_english',
    how='left'
)
```

Základní graf


```
In [84]: plt.figure(figsize=(10, 7))

sns.scatterplot(
    data=sales_with_counts,
    x='product_count',
    y='total_quantity_sold',
)

plt.title('Vztah mezi počtem prodaných produktů v kategorii a počtem nabízených produktů v kategoriích')

plt.tight_layout()
plt.show()
```

1e6



Vylepšený graf

```
In [85]: plt.figure(figsize=(10, 7), facecolor=palette['rich_black'])

# Velikost bodů
scaling_factor = 0.001
point_sizes = sales_with_counts['total_quantity_sold'] * scaling_factor

ax = sns.scatterplot(
    data=sales_with_counts,
    x='product_count',
    y='total_quantity_sold',
    s=point_sizes,
    alpha=0.7,
    color=palette['mountain_meadow'],
    edgecolor=palette['anti-flash_white']
)

# Regresní přímka
sns.regplot(
    data=sales_with_counts,
    x='product_count',
    y='total_quantity_sold',
    scatter=False,
    color=palette['anti-flash_white'],
    line_kws={'linestyle': '-', 'alpha': 0.5},
    ci=None
)

# Detekce outlierů
Q1 = sales_with_counts['total_quantity_sold'].quantile(0.25)
Q3 = sales_with_counts['total_quantity_sold'].quantile(0.75)
IQR = Q3 - Q1
multiplier = 2.0
lower_bound = Q1 - multiplier * IQR
upper_bound = Q3 + multiplier * IQR

outliers = sales_with_counts[
    (sales_with_counts['total_quantity_sold'] < lower_bound) |
    (sales_with_counts['total_quantity_sold'] > upper_bound)
]

# Přidání popisků k outlierům
for _, row in outliers.iterrows():
```

```

ax.annotate(
    row['product_category_name_english'],
    (row['product_count'], row['total_quantity_sold']),
    xytext=(-2, 5),
    textcoords="offset points",
    ha='right',
    color=palette['anti-flash_white'],
    fontsize=10,
    bbox=dict(
        boxstyle='round,pad=0.3',
        facecolor=palette['rich_black'],
        edgecolor=palette['mountain_meadow'],
        alpha=0.25
    )
)

# Styl grafu
ax.set_facecolor(palette['rich_black'])
sns.despine(top=True, right=True, bottom=True, left=True)
plt.grid(False)

ax.yaxis.set_major_formatter(FuncFormatter(format_ticks))

plt.xticks(fontsize=14, fontweight=500, color=palette['anti-flash_white'])
plt.yticks(fontsize=14, fontweight=500, color=palette['anti-flash_white'])
ax.tick_params(
    axis='both',
    which='both',
    color=palette['anti-flash_white'],
    length=5,
    width=1,
)


plt.xlabel('Počet nabízených produktů', color=palette['anti-flash_white'], fontsize=14, labelpad=15)
plt.ylabel('')

plt.suptitle(
    'Závislost prodeje na počtu produktů v kategorii'.upper(),
    y=1.00,
    fontsize=18,
    fontweight=500,
    color=palette['anti-flash_white']
)

```

```
plt.tight_layout()  
plt.show()
```

ZÁVISLOST PRODEJŮ NA POČTU PRODUKTŮ V KATEGORII



4) Odkaz na dataset, případně další literaturu

Dataset: Brazilian E-Commerce Public Dataset by Olist

Odkaz na dataset: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>